Genişletilmiş Ek — Gerçek Zamanlı YOLO Modellerinin İnce Ayarında Artırma ve Kayıp Müdahalelerinin Çok Tohumlu Değerlendirmesi: PASCAL VOC ve KITTI Üzerine Bir İnceleme

Ahmed Gürkan ÖZÇELİK[1*] and Ufuk ASIL[1]

[1*]Ostim Technical University, OSTİM, 100. Yıl Bulvarı, 55/F, 06374, Yenimahalle, Ankara, Türkiye.

*Corresponding author(s). E-mail(s): 250801017@ostimteknik.edu.tr;
Contributing authors: ufuk.asil@ostimteknik.edu.tr;

Özet

Bu belge, yukarıdaki başlıklı makalenin genişletilmiş ekidir (GitHub deposu, `paper/ek.pdf`): Bölüm A koşum dökümünü, Bölüm B VOC ek sonuçlarını, Bölüm C KITTI ek sonuçlarını, Bölüm D yöntem ayrıntılarını ve hesap notlarını verir. Harfli numaralar (Bölüm B.1, Tablo B1, Şekil C1, Denklem D1 gibi) bu belgeye aittir; harfsiz bölüm, tablo, şekil ve denklem numaraları ile "makale Ek A" atıfları ana makaleye aittir.

Ek A Koşum dökümü

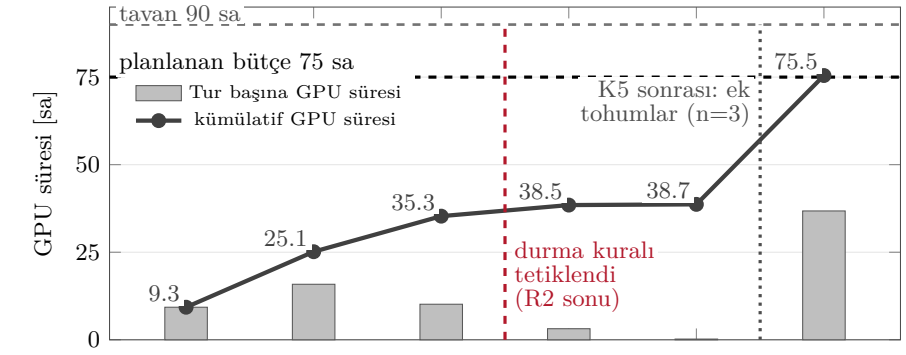
Bu bölüm, makalenin Ek A'sında özetlenen VOC koşum dökümünün tablosunu (Tablo A1) ve tur başına GPU süresi ile en yüksek eğitim kartının Δ'sını gösteren şekli (Şekil A1) verir; durma kuralının uygulanışı, kilit sonrası işler ve GPU bütçesi makalenin Ek A'sındadır.

Tablo A1 Deney kaydı: tur ve kart başına koşum damgası sayısı, kanıt niteliğindeki aşama-3 koşumları ve GPU süresi [sa]; toplam 60 koşum.

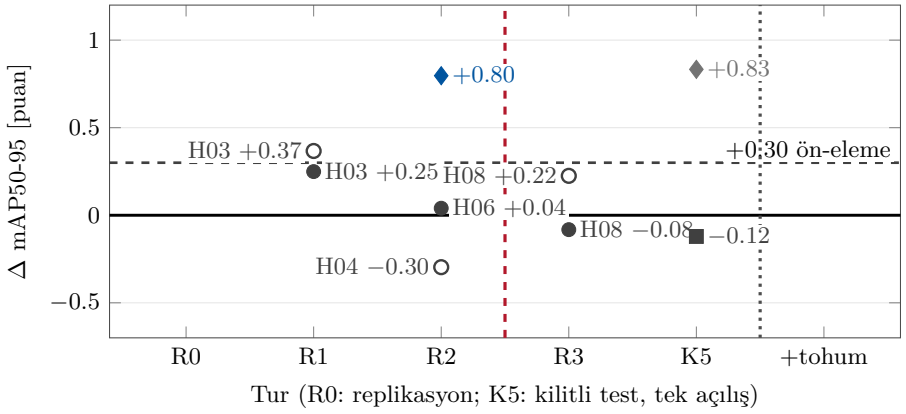
Tur	Kart / grup	Koşum	Aşama-3	GPU [sa]	Karar
Tur 0	taban model	8 (1 geçersiz)	3	9.20	YEŞİL
	kalibrasyon	3	0	0.10	kapı
Tur 1	H01	3	1	3.47	KAPAT (ön-eleme, tohum 0)
	H02	3	1	3.17	KAPAT (ön-eleme, tohum 0)
	kontrol (mosaic hep açık)	2	0	0.19	kontrol
	H03	5	3	9.01	KAPAT (3 tohum ort.)
Tur 2	H04	3	1	3.10	KAPAT (ön-eleme, tohum 0)
	H05	4 (1 geçersiz)	1	3.75	KAPAT (ön-eleme, tohum 0)
	H06	3	1	3.11	KAPAT (ön-eleme, tohum 0)
	H07	1	1	0.19	KAZANÇ-B (TTA)
Tur 3	H08	3	1	3.16	KAPAT (ön-eleme, tohum 0)
K5	taban model (test)	3	3	0.06	değerlendirme
	H03 (test)	3	3	0.05	değerlendirme
	TTA (test)	3	3	0.09	değerlendirme
Ek tohum	H01	2	2	6.56	ön-eleme doğrulandı (n=3)
	H02	2	2	5.93	ön-eleme doğrulandı (n=3)
	H04	2	2	5.81	ön-eleme doğrulandı (n=3)
	H05	2	2	6.71	ön-eleme doğrulandı (n=3)
	H06	2	2	5.84	ön-eleme doğrulandı (n=3)
	H08	2	2	5.89	ön-eleme doğrulandı (n=3)
	H07 WBF tanısı	1	1	0.04	tanı
Toplam		**60**	**35**	**75.45**	hedef 75 sa, tavan 90 sa

Koşum: duman testi, kısa ön deneme ve tam aşama damgaları. Geçersiz: yetim süreç (rc=96), güvenlikle durmuş H05 (rc=95); süreye dahil, kanıta değil. K5: eğitimsiz test. Ek tohum: yalnız doğrulama. Satır toplamları yuvarlama nedeniyle toplamdan ±0.02 sa ayrılabilir; toplamlar yuvarlanmamış sürelerdendir.

(a) Tura göre GPU süresi: tur başına (çubuk) ve kümülatif (çizgi)



(b) Tur başına en iyi eğitim-zamanı kartı (doğrulama) ve kilitli test (K5)



● en iyi eğitim-zamanı kartı, 3 tohum ort. ○ tohum-0 ön-elemesinde en iyi kart
◆ eğitimsiz TTA, doğrulama (DOĞRULANDI kuralı) ◆ eğitimsiz TTA, test (keşifsel)
■ test üzerinde H03 (3 tohum ort.)

Şekil A1 GPU bütçesi (a); tur başına en iyi eğitim kartının taban modele göre Δ mAP50-95'i [puan] (b): dolu daire 3 tohum ort. (R2–R3'te kilit sonrası tohumlarla), boş daire tohum-0 ön-eleme; elmas TTA, kare K5 testi. Kırmızı çizgi: durma kuralı; "+tohum": ek tohumlar.

Ek B VOC ek sonuçları

Bu ek, diğer kartların mekanizma notlarını, iki yöntem ayrıntısını (kutu-tabanlı copy-paste adımları; H07 Soft-NMS tanımı ve doğrulama prosedürü) ve ana metindeki VOC bulgularını tamamlayan mutlak değerleri, ikincil ölçütleri, H07 satırlarını, hata türü kırılımını, copy-paste doz karşılaştırmasını ve nitel paneli verir. Buradaki ikincil ölçütlerin hepsi keşifseldir.

B.1 Diğer kartların mekanizma notları

Bu alt bölüm ana metinde birer cümleye indirilen mekanizma notlarının tamamıdır (VOC doğrulaması; puan, tohum-eşli Δ, üç tohum ort. $\pm$ s.d.).

Ölçek ekseni: H01 ve H04.

H01 eğitim girdisini batch başına 480–800 px arasında değiştirdi (üç tohumda da 11 farklı boyut); H04 mosaic ölçek aralığını daralttı (her tohumda 97 200 batch'in tümü etkilendi). Müdahale iki kartta da devredeydi, ama ikisi de mAP50-95'i yükseltmedi: H01'in tohum işaretleri karışıktır, H04'ün üçü de negatiftir ve aralığı sıfırı kapsar. H04 5 epoch'luk kısa ön denemede (tohum 0) taban modelin $+0.56$ önündeyken 100 epoch'ta -0.85'e döndü (tohum 0: -0.30); kısa ön deneme son sıralamayı öngörmeyen bir kod sağlığı kapısıdır (tek kartlık örnek). Genlik büyütülmediği için "varsayılan ölçek genliği optimumdur" denemez.

Kutu kaybı: H02 ve H06.

H02'de (Inner-CIoU, $r = 0.75$) kayba giren IoU $-$ Inner-IoU farkı üç tohumda ortalama 0.027'dir; terim devrededir. mAP50-95 üç tohumda da düştü (Holm-7 sonrası $p = 0.244$) ve hedeflenen AP_{75} yükselmedi (-0.42 ± 0.27). H06 (kutu kazancı $7.5 \rightarrow 10$) AP_{75}'i de değiştirmedi ($+0.07 \pm 0.30$). Taban modelin yüzüncü epoch kayıp payları kutu %30.1, sınıflandırma %23.5, DFL %46.3'tür; en büyük pay olan DFL'nin ağırlığı denenmedi. AP_{75} açığı kutu-IoU teriminin ne biçimiyle ne ağırlığıyla kapandı; atama, kalite hedefi ya da DFL aday açıklamalardır. Inner-IoU'nun raporlanan kazançlarının [1] COCO ön-eğitimli, TAL atamalı bir ince ayara taşınacağı varsayımı desteklenmedi.

Copy-paste dozu: H03 ve H08.

H03 yapıştırmayı mosaic'lerin %11.1'ine, H08 %47.8'ine uyguladı; ölçülen doz sırasıyla 0.142 ve 0.671 nesne/mosaic'tir. H03'ün tohum-0 farkı ön-eleme eşiğini geçti, ama üç tohum ortalaması SÜRDÜR ölçütünün altında kaldı; mAP50 kazancı üç tohumda da pozitifken AP_{75} farkı -0.32 ± 0.18'dir. Doz ve havuz birlikte genişleyince mAP50 kazancı $+0.74 \pm 0.16$'dan (H03) $+0.25 \pm 0.14$'e (H08) indi; artan bir etki gösterilemedi (Şekil B2). "Doygun mekanizma" yorumu, ayrıştırılmamış iki değişken nedeniyle zayıf bir hipotezdir. Doğrulamadaki mAP50 izi testte görülmez (Bölüm 5.3); küçük nesne örneklerini çoğaltmak, çözünürlükle ilişkili görünen açığı bu rejimde kapatmadı (Bölüm 5.2).

H05 ayrıntıları.

H05'in doğrulama mAP50-95 kaybı -2.87 ± 0.33 puandır. VFL gradyan normu BCE'nin 0.34'üdür (üç tohumda 0.342, 0.341, 0.341; kayıp değeri 0.031; tanım: makale Ek A.5). Uygulama iki birim testinden geçti: $\alpha = 1$, $\gamma = 0$ ve $y = 0$ (yalnız negatif hücreler) iken kayıp BCE ile birebir eşleşir (pozitifler hâlâ t ile ağırlıklanır; H05-pos'un tanımı); pozitif dalın $w = t$ ağırlığı ve gradyanı, elle yazılmış bir karşılaştırma uygulamasına karşı çift duyarlıkla denetlendi. İlk koşumu durduran güvenlik eşiği, taban modelin 5. epoch değerinden 0.03 çıkarılarak H02'nin BCE eğrisinden devralınmıştı.

B.2 Kutu-tabanlı copy-paste adımları

Dönüşüm (Bölüm 3.2) mosaic'ten sonra, RandomPerspective'ten önce çalışır. Kesişimin ilk kutunun alanına oranı (intersection over area, IoA) $\mathrm{IoA}(b_j, b_l) = |b_j \cap b_l|/|b_j|$ olmak üzere, olasılık p ile şu adımlar uygulanır:

1. Aday kümesi $\mathcal{A} = \{\, j : \sqrt{A_j} \le \tau_A,\ \max_{l \neq j} \mathrm{IoA}(b_j, b_l) \le 0.1 \,\}$ kurulur; A_j kutunun mosaic tuvalindeki piksel alanıdır ve IoA koşulu yamaya başka nesne parçası girmesini önler.
2. $k \sim U\{1, 2, 3\}$ çekilir ve $\mathcal{A}$'dan $\min(k, |\mathcal{A}|)$ nesne rastgele seçilir.
3. Her nesne yeniden ölçeklenmeden, RandomPerspective sonrasında kalan merkez $s \times s$ penceresinde, mevcut tüm kutularla (yeni yapıştırılanlar dahil) kesişimi boş bir konuma yerleştirilir; en çok 10 deneme yapılır, yer bulunamazsa aday atlanır.
4. Piksel yaması kenarları 3 piksellik alfa harmanlamasıyla yapıştırılır (fikir: [2]; 3 piksel bu çalışmanın seçimidir); sınıf etiketi korunur ve kaynak kutunun boyutuyla yeni bir kutu eklenir.

B.3 H07: Soft-NMS tanımı ve doğrulama prosedürü

Soft-NMS satırlarında (S) tutulan kutu m ile örtüşen b_i'nin skoru sınıf başına Gauss kuralıyla bozulur [3]:

$$s_i \leftarrow s_i \exp\!\big(-\mathrm{IoU}(m, b_i)^2/\sigma\big), \qquad \sigma \in \{0.3,\ 0.5\}; \tag{B1}$$

aday havuzu ön-NMS'siz, skoru ≥ 0.001 olan en yüksek 1000 tespittir.

Doğrulama kümesi sıralı dosya adına göre çift ve tek indeksle iki yarıya (A ve B, 500/500) bölünür. Aile başına yarım A'da R0'dan $\Delta > 0$ veren en iyi satır aday olur ve şu üç koşulu birlikte sağlarsa DOĞRULANDI sayılır: (a) yarım B'de $\Delta \ge +0.30$; (b) tam doğrulama kümesinde görüntü-düzeyi eşli bootstrap'ın ($B = 200$) tek yönlü yüzde 90 alt sınırı sıfırın üstünde; (c) taban modelin tohum 1 ve 2 ağırlıklarında aynı satırın ortalama Δ'sı $\ge +0.20$ ve iki değer de pozitif. Gecikme sınıflaması (KAZANÇ-A/B) için bkz. Bölüm 3.2.

B.4 Mutlak değerler ve tohum 1–2 ortalamaları

Tablo B1 doğrulama ve test mAP50-95'in mutlak değerlerini ve ön-eleme tohumu hariç tohum 1–2 ortalamasını verir. Taban model doğrulamada 63.07 ± 0.41, testte 63.49 ± 0.11 puandır; TTA'lı test değeri 64.32 ± 0.11'dir. Elenen kartların bağımsız tohum

Tablo B1 VOC mutlak mAP50-95 [puan] (ort. ± s.d., n=3) ve tohum 1–2 ortalama Δ. Renk: yalnız Holm-anlamlı (kırmızı kötü).

Yöntem	Doğrulama mAP50-95	Test mAP50-95	Δ tohum 1–2
Taban model	63.07 ± 0.41	63.49 ± 0.11	–
H01 multi_scale	62.86 ± 0.20	–	−0.35
H02 Inner-CIoU	62.72 ± 0.32	–	−0.41
H03 copy-paste	63.32 ± 0.17	63.37 ± 0.20	+0.19
H04 scale	62.22 ± 0.41	–	−1.13
H05 Varifocal	*60.20 ± 0.17*	–	−2.86
H06 kutu kazancı	63.11 ± 0.55	–	+0.27
H08 yüksek doz	62.99 ± 0.14	–	−0.24
Taban model + TTA (eğitimsiz)	–	64.32 ± 0.11	–

Δ tohum 1–2: ön-eleme tohumu s0 hariç bağımsız ortalama (doğrulama). Test yalnız taban model, H03 ve TTA için açıldı. Renk ölçütü: doğrulamada Holm-7, testte Holm-12 ve sıfırı kesmeyen GA (Tablo 4).

1–2 ortalamalarından hiçbiri +0.30'u aşmaz; en yakını H06'dır (+0.27; tohum 0'da −0.42). Tohum 0'da elenen H06'nın bağımsız tohumlarda eşiğe en yakın kart olması, tek tohumlu kapının yanlış-negatif riski taşıdığını hatırlatır (Bölüm 5.1).

B.5 Test ikincil ölçütleri

Tablo B2 VOC ikincil ölçütler: taban modele göre tohum-eşli Δ [puan], n=3. p: çift yönlü eşli t; Holm-12: 12 testlik aile.

Karşılaştırma	Metrik	Δ ort.±s.d.	p	Holm-12 p
H03 kutu copy-paste (test)	mAP50	−0.02 ± 0.21	0.883	1.000
	mAP75	−0.11 ± 0.13	0.268	1.000
	AP_S	+0.81 ± 2.55	0.639	1.000
	AP_M	+0.48 ± 0.14	0.027†	0.222
	AP_L	−0.23 ± 0.09	0.048†	0.333
Taban model + TTA (test)	mAP50	+0.10 ± 0.27	0.579	1.000
	mAP75	+1.12 ± 0.30	0.023†	0.222
	AP_S	−0.48 ± 0.82	0.416	1.000
	AP_M	−1.07 ± 0.18	0.009†	0.112
	AP_L	+1.50 ± 0.36	0.019†	0.210
H03 (doğrulama)	mAP50	+0.74 ± 0.16	0.015	–

mAP50-95 satırları: Tablo 4. Holm-12: K5 ailesi (H03, TTA × 6 metrik; H03 mAP50-95 dahil, konservatif); en küçüğü 0.112, renk yok. †: düzeltmesiz $p < 0.05$, Holm sonrası anlamlı değil.

Tablo B2 H03 ve TTA'nın test ikincil ölçütlerini verir. Düzeltmesiz $p < 0.05$ veren farklar vardır (H03'te AP_M ve AP_L; TTA'da mAP75, AP_M ve AP_L), ancak on iki testlik ailede Holm sonrası en küçük p 0.112'dir; bu farklar yön olarak okunur. TTA'nın test mAP50-95 farkı için tohum düzeyindeki t aralığı [+0.29, +1.38]'dir.

H03'ün doğrulamada üç tohumda pozitif olan mAP50 kazancı (+0.74 ± 0.16, $p = 0.015$) testte −0.02 ± 0.21'dir. Doğrulamanın %70'i VOC2012 olduğundan kaynak farkı sınandı: mAP50 farkı VOC07 alt kümesinde +0.73 ± 1.23, VOC12'de +0.64 ± 0.58'dir (303/697 görüntü). Hipotez desteklenmedi ve `best.pt` seçim iyimserliği sınanmadı.

B.6 H07 eğitimsiz çıkarım satırları

Tablo B3 H07 eğitimsiz çıkarım satırları (doğrulama, tohum 0) ve TTA test satırı: Δ mAP50-95 ve gecikme. Mavi doğrulandı; kırmızı $\Delta \leq -0.5$ ya da >1.10×.

Satır	Tanım	Δ mAP50-95	Δ AP_S	Δ AP_L	[ms]	[×]	Durum
R0	Referans (NMS 0.7, 640 px)	0.00	0.00	0.00	8.45	1.00	referans
N50	NMS IoU 0.5	*−0.54*	−0.93	−0.56	8.25	0.98	aday değil
N60	NMS IoU 0.6	−0.21	−0.20	−0.20	8.30	0.98	aday değil
N80	NMS IoU 0.8	−0.10	+0.03	−0.03	8.33	0.99	aday değil
S03	Soft-NMS σ=0.3	−0.12	−0.11	−0.03	9.10	1.08	aday değil
S05	Soft-NMS σ=0.5	*−0.58*	+0.06	−0.51	9.14	1.08	aday değil
U704	test imgsz 704	−0.31	+2.41	−0.82	8.92	1.06	aday değil
U768	test imgsz 768	*−2.06*	+4.55	−3.41	9.43	1.12†	aday değil
U832	test imgsz 832	*−5.19*	+4.94	−7.24	9.61	1.14†	aday değil
T1	TTA 1, 0.83, 0.67 + flip	**+0.80**	−0.12	+1.58	21.68	*2.57*	KAZANÇ-B
T2	TTA 1, 1.2, 1.4 + flip	*−4.12*	+2.75	−5.99	21.54	*2.55*	aday değil
W1	WBF (T1 dalları)	−0.28	+0.41	+0.65	25.27	*2.99*	aday değil
W2	WBF (T2 dalları)	*−5.74*	+5.10	−7.85	26.14	*3.10*	aday değil
T1 test	TTA, 3 tohum, test	+0.83 ± 0.22†	−0.48	+1.50	21.64	*2.29*	KAZANÇ-B

Doğrulama: taban model tohum-0 `best.pt` (R0 = 8.45 ms); TTA test: kendi oturumu (taban model 9.43 ms). Kırmızı Δ iki doğrulama yarısında da negatif (GA yok). †: oran tek-koşum gürültüsü (1.14×) içinde (renksiz) ya da Δ düzeltmesiz $p < 0.05$.

Tablo B3, H07'nin on iki eğitimsiz satırını R0 referansına göre ve TTA test satırını gecikmeyle verir; Şekil 3 aynı satırları çizer (Bölüm 5.2). T1 tek DOĞRULANDI satırıdır ve gecikme oranı nedeniyle KAZANÇ-B sayılır. WBF tanısının iki ek ayrıntısı şudur. WBF'nin IoU eşiği NMS'inkinden gevşek olduğundan 0.6 eşiğinde tek dal bile ham NMS'ten ayrılır. Varsayılan WBF ayarı yüksek IoU'da da kaybettirdi (T1'e göre AP_{75} −1.33, AP_{90} −2.15; Bölüm B.7).

B.7 Eğitimsiz çıkarım: WBF tanısı

Varsayılan WBF ayarı T1'in mAP50-95'ini -1.08 düşürdüğünden doğrulamada, test sonrası ve keşifsel bir tanı yapıldı (kazanç iddiası değildir). Uygulama doğruydu: 8 birim testinin 8'i geçti ve tek dallı WBF, IoU eşiği $\approx$1 iken ham NMS'ten $+0.000$ puan ayrıldı. Kayıp iki ayardan gelir. Ortalama skor füzyonunda üç görünümden azında görülen kutunun skoru küçülür; ölçek dalları her boyuttaki nesneyi göremediğinden bu ceza sıralamayı bozar ve maksimum füzyonu $+0.98$ puan getirdi. IoU eşiğini 0.7'ye çıkarmak ortalama füzyonda da kaybı azalttı; iki ayarın payları ayrıştırılmadı. Izgaranın en iyi ayarı (IoU 0.7, maksimum) T1'i $+0.45$ geçti; doğrulamada seçildiği için bu kanıt değil, etkinin ayara bağlı olduğunun göstergesidir.

B.8 Kart başına ikincil ölçütler (doğrulama)

Eğitim kartlarının boyut ve eşik ölçütlerindeki farklar şunlardır. H01'de AP_S -0.30 ± 2.24, AP_M $+0.84$; H04'te AP_S -1.06 ± 0.68, AP_M -0.75'tir. H02'de AP_S değişimi $+1.39 \pm 1.09$'dur. H06'da mAP50 $+0.30 \pm 0.55$'tir. Bu AP_S değişimlerinin hepsi taban modelin tohum aralığı (2.87 puan) içinde kalır. H05'in kaybı üç boyut sınıfında görülür: AP_S -2.39, AP_M -4.06, AP_L -2.10.

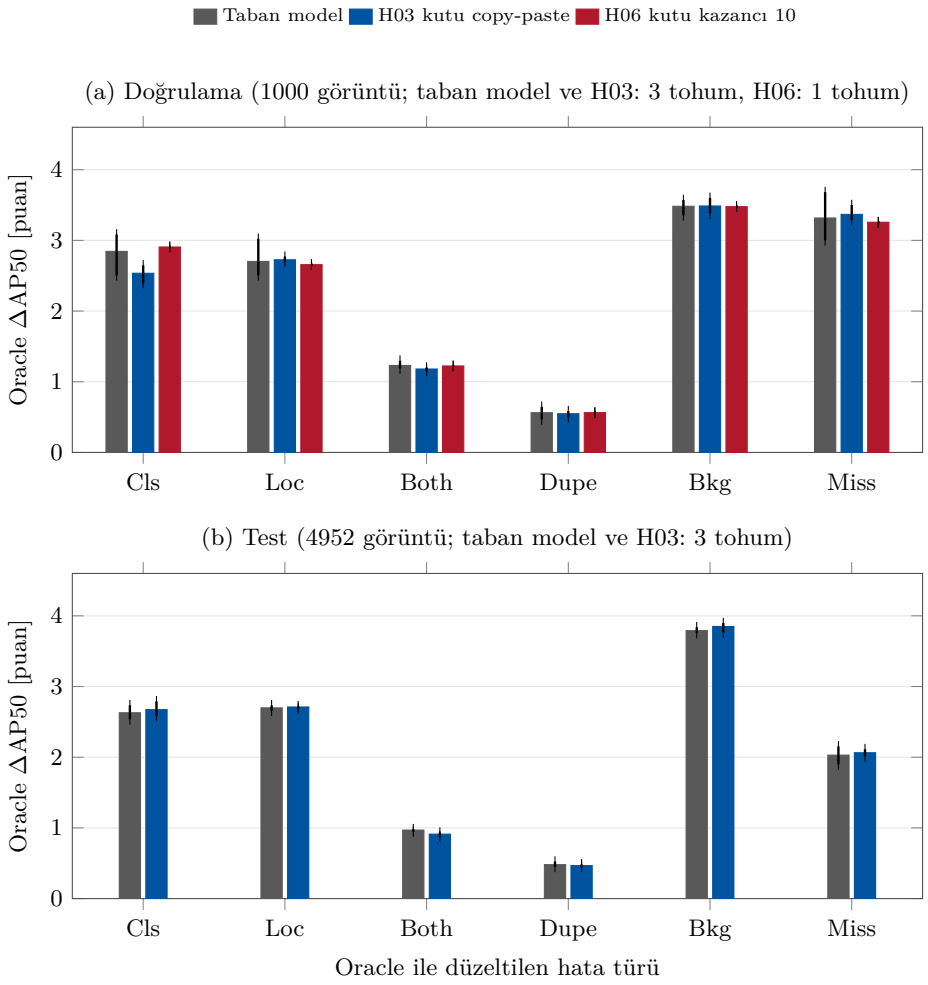
H05'in son 10 epoch'taki doğrulama kazancı $+0.20$, $+0.27$, $+0.23$, taban modelinki $+0.04$, $+0.16$, -0.03 puandır. Aradaki fark ($\approx$0.18 puan) tek bir doğrulama ölçümünün gürültüsünün (Bölüm 5.3) çok altındadır ve bu evre mosaic'in kapandığı evredir; yakınsama hipotezi bu yüzden yalnız zayıf desteklenir.

H05c'nin tohum başına değerleri şunlardır: $\Delta_{\mathrm{c},s}$ $+0.02$, -1.15, -0.40; D_s $+2.90$, $+2.04$, $+2.13$. Tohum başına geri kazanım 1.01, 0.64 ve 0.84'tür (ortalama 0.83). Kalan farkta iki tohum negatif, biri $\approx$0'dır. H05c koşumlarında ölçülen VFL/BCE gradyan normu oranı 0.347–0.349'dur. En iyi epoch H05c'de 96, 96 ve 95, H05'te 100, 100 ve 100'dür. Karar kuralı, geçersiz bir koşumun yeniden koşulmayıp "koşulamadı" olarak raporlanmasını öngörüyordu; büyüklüğün kaybı açıklamadığı durum ise biçim hipotezini güçlendirecek ama kanıtlamayacaktı.

B.9 Hata türü kırılımı

Tespitler TIDE'a benzer biçimde hata türlerine ayrılır [4]; eşleştirme pycocotools ile (en çok 300 tespit) yapılır. Doğru pozitif (true positive, TP), IoU$\geq$ 0.5 ile eşleşen tespittir; Dupe, GT'si daha yüksek skorlu bir kutuyla alınmış IoU$\geq$ 0.5 tespit; Cls, başka sınıf GT ile IoU$\geq$ 0.5; Loc, aynı sınıf GT ile 0.1 $\leq$IoU$<$ 0.5; Both, başka sınıf GT ile 0.1 $\leq$IoU$<$ 0.5; Bkg, hiçbir GT ile IoU$\geq$ 0.1 olmayan tespit; Miss, hiçbir kutuyla IoU$\geq$ 0.5 eşleşmeyen GT'dir. Oracle $\Delta\mathrm{AP}_{50}$, ilgili hata düzeltilip (Loc: kutu GT'ye yapıştırılır, Cls: sınıf düzeltilir, Dupe, Both ve Bkg: kutu silinir, Miss: GT silinir) yeniden değerlendirildiğinde AP_{50}'deki artıştır. Kırılım işletim noktasında (skor $\geq$ 0.25) ve eşiksiz ($\geq$ 0.001), boyut ve sınıf düzeyinde ayrıca raporlanır.

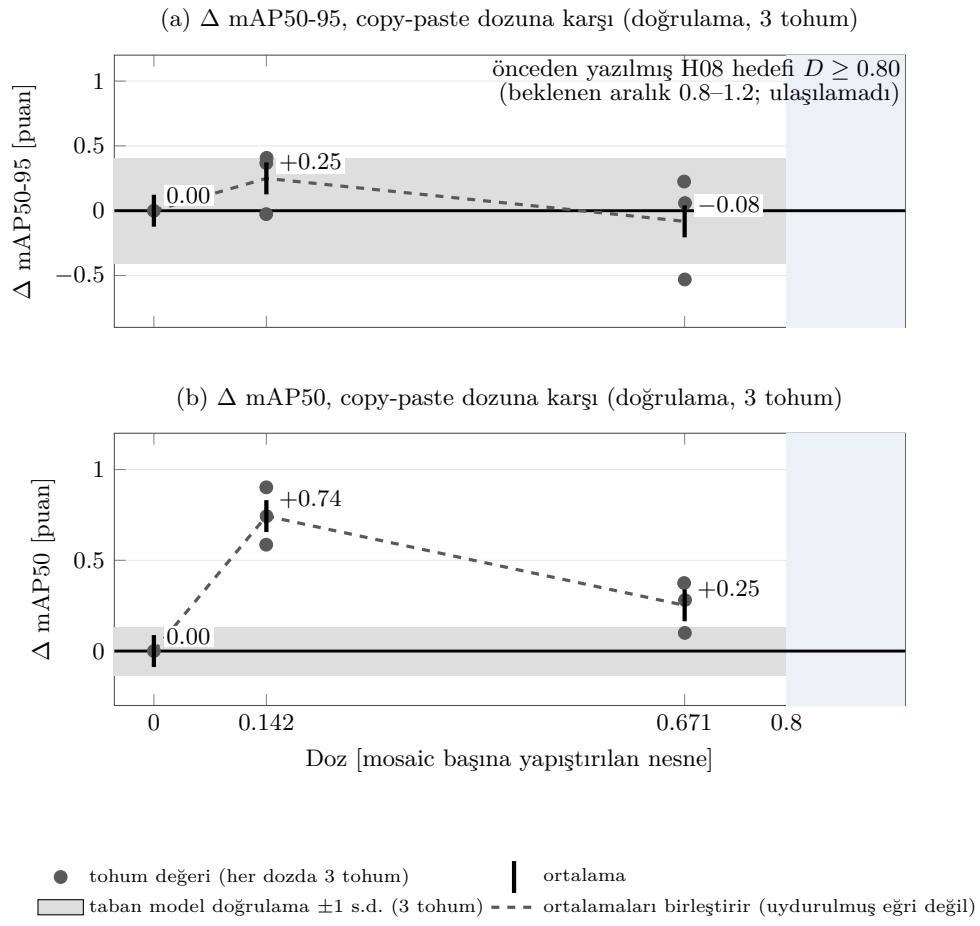
Şekil B1 hata türlerinin oracle ΔAP50 maliyetini taban model, H03 ve H06 için karşılaştırır (test kırılımı keşifsel; H06 yalnız valda, tohum 0). Arka plan yanlış pozitifi (Bkg) iki kümede de en maliyetli türdür (val 3.48, test 3.79 puan; Miss: 3.32 ve 2.03). H03 ve H06 çubukları taban modelden valda en çok 0.31, testte en çok 0.06 puan ayrılır; hata profili kaymadı ve bu, mAP'teki sıfıra yakın farkla tutarlıdır.



Şekil B1 Hata türü oracle'ı: ilgili hata düzeltilirse ΔAP50 [puan] (Cls sınıf, Loc konum, Both ikisi, Dupe yinelenen, Bkg arka plan, Miss kaçırılan). Çubuk ortalama, bıyık tohum min–maks; (a) doğrulama, (b) test.

B.10 Copy-paste doz karşılaştırması

Şekil B2 doğrulama kazancını yapıştırma dozuna (mosaic başına nesne) karşı çizer: 0 (taban model), 0.142 (H03), 0.671 (H08; H03'ün 4.7 katı). H08 olasılığı ve aday havuzunu birlikte değiştirdiğinden (Bölüm 3.2) doz ile boyut karışımı ayrışmaz; bu bir doz–yanıt eğrisi değil, üç noktalı bir karşılaştırmadır. ΔmAP50 $+0.74 \pm 0.16$'dan $+0.25 \pm 0.14$'e iner; H08'de ΔAP_S $+0.31 \pm 2.84$'tür. Doz ve havuz birlikte genişleyince kazanç büyümedi ("artan bir etki gösterilemedi").



Şekil B2 Kutu-tabanlı copy-paste dozuna (mosaic başına yapıştırılan nesne) karşı doğrulama Δ mAP50-95 (a) ve Δ mAP50 (b), 3 tohum. H08 yapıştırma olasılığını ve aday havuzunu birlikte değiştirir; doz tek başına ayrıştırılmamıştır.

B.11 Nitel panel

Şekil B3 aynı test görüntülerinde GT, taban model, H03 ve taban model+TTA tespitlerini (tohum 0, skor ≥ 0.25) iki yönün uç örnekleri ve bir rastgele kareyle gösterir; seçim ölçütü başlıktadır (1642 görüntülük havuz; taban model görüntü-AP Q1–Q3: 0.497–0.896). TTA bir sahnede görüntü-AP'sini 0.522'den 0.971'e çıkarırken bir otomobil sahnesinde 0.895'ten 0.248'e düşürür; H03 de ilk sahnede sıçrar, yani farklar TTA'ya özgü değildir. Tüm geçerli görüntülerde (tohum 0) TTA'nın ortalama görüntü-AP farkı −1.26'dır; görüntülerin %31.8'i iyileşir, %38.4'ü kötüleşir (H03: +0.36; %35.5 ve %34.7). Veri kümesi mAP'i ise +0.88 artar; kazanç tek tip bir görsel iyileşme değildir (keşifsel).



Şekil B3 VOC07 testinde altı görüntüde GT, taban model, H03 ve TTA tespitleri (tohum 0). Mavi kalın/kırmızı eğik: taban modele göre iyi/kötü. Seçim: ≥2 GT'li, üç yöntemde tespitli, taban model AP'si Q1–Q3 içindeki adaylardan TTA kazancı/kaybı, küçük nesneli H03 kazancı/kaybı, rastgele 1.

Ek C KITTI ek sonuçları

Bu ek, KITTI deneyinin (Bölüm 7) kurulum ayrıntılarını, ikincil sonuçlarını, H05'in eğitim eğrisini, `best.pt` seçimi analizini, kilit sonrası sağlamlık analizini ve eğitimsiz çıkarım ayrıntılarını verir.

C.1 Kurulum ayrıntıları

Sorular, kurallar ve eğitim ayrıntıları.

S1 model başına iki aileyle yanıtlanır: iyileşme ailesinde kabul ölçütünü sağlayan kart sayısı ve yönlü replikasyon ailesinde VOC'taki kaybın yinelenip yinelenmediği. S2, VOC'ta koşulan iki bileşen kartının katkı ve toplamsallık ölçütleriyle yanıtlanır. Kural belgesindeki sonraki değişiklikler S2'nin VOC kartlarına uygulanmaz. VOC'taki fiilî optimizatör davranışı şu ayarlarla sabitlendi: MuSGD, öğrenme hızı 0.01, momentum 0.937, bias ısınması 0. Copy-paste parametreleri değişmedi; mosaic başına yapıştırılan nesne H03'te 0.98, H08'de 2.00'dir. YOLO26n'de H02 ve H05 yamaları iki eğitim başlığına da uygulanır (başlık sayacıyla denetlendi). Üç tohumla Holm-5'in ilk adımında %50 güçteki kritik etki $\approx 2.8\, s_{\Delta}$'dır; kabul edilmeyen kart için "kabul ölçütü sağlanmadı" denir. H07'de NMS'siz YOLO26n'de NMS, Soft-NMS ve WBF satırları uygulanamaz.

Bölme ve yok-say kuralı.

Hazır Ultralytics bölmesi dışında, 3B tespit çalışmalarında kullanılan 3712/3769 eğitim/doğrulama bölmesi de kullanılmadı: ayrı bir test bölümü sunmaz ve aynı sahnenin farklı kayıt adlarıyla gelen karelerini birleştiren bir denetim (NCC) içerdiğini doğrulayamadık. Sahne grupları eğitim, doğrulama ve test bölümlerine, her sınıfın nesnelerinin en az %40, %5 ve %10'u ilgili bölmede olacak ve tek bir grup doğrulama ya da test hedef büyüklüğünün %25'ini aşmayacak biçimde atandı. Bölmeler arası en yüksek NCC test–eğitim için 0.855, doğrulama–eğitim için 0.888'dir. Test bölümü 6 212 nesne ve 2 436 `DontCare` bölgesi içerir. Değerlendirmede `DontCare` bölgeleri her sınıf için COCO tarzı bir yok-say bölgesi (`iscrowd`) olarak eklenir. Tespitler önce gerçek nesnelerle eşleşir; yalnız eşleşmeyen tespit, bir `DontCare` bölgesiyle örtüşme oranı (IoA: kesişimin tespit alanına oranı) o anki IoU eşiğine eşit ya da büyükse yok sayılır. Resmî KITTI AP'si ise sınıf başına sabit eşik ve zorluk düzeyleri kullanır. `DontCare`'siz mAP ikincil olarak Tablo C1'de verilir.

Eğitim, sağlık kapısı ve öğrenme denetimi.

YOLO26n'nin kayıp kodu v8.4.165 `E2ELoss`'tur. KITTI'deki yineleme sayısı VOC'takinin (24 300) ≈3.1 kat altındadır. Başlık sayacı her H02 ve H05 koşumunda okundu. Bir eğitim koşumu YOLO11s için 1.68–1.83, YOLO26n için 1.17–1.31 GPU saati sürdü. Her koşum otomatik bir kapıdan geçer: batch'in sessizce küçültülmemesi, yamanın gerçekten çağrılması ve bir öğrenme denetimi. Öğrenme denetimi geçerlilik ölçütüdür: `results.csv` tam 100 epoch içerir, kayıp ve metrik değerleri sonludur, öğrenme hızı planı aynı modelin tohum-0 taban modeliyle epoch epoch aynıdır, 81–90. epoch'ların ortalama eğitim (kutu + sınıflandırma) kaybı 11–20. epoch'larınkinden düşüktür ve en iyi doğrulama mAP50-95 0.02'nin üstündedir. Taban modele göreli bir eşik konmadı, çünkü güçlü negatif kartları sansürlerdi. Geçmeyen koşum Δ'ya girmez.

En iyi epoch'un 20'den küçük olması geçersizlik değil, uyarıdır; kural tüm kartlara ve iki modele aynı biçimde uygulanır. Bu denetimin kural belgesine girişi ve test betiğine `last.pt` değerlendirmesinin eklenmesi kural değişiklikleridir (Bölüm 9). YOLO11s kuyruğu bitene kadar izleme yalnız olay türü, koşum kimliği ve çıkış koduyla yapıldı.

Çözünürlük.

KITTI karelerinin çoğu 1242×375'tir (testte 1 396/1 504; en-boy oranı 3.31) ve 640 px girişte uzun kenar ≈0.52 ölçeğine inerek kare ≈640×193 olur. Testte pedestrian ve cyclist nesnelerinin COCO "küçük" sınıfında (alan $< 32^2$ px) olanlarının oranı özgün çözünürlükte %19.1, 640 px'te %65.6'dır. VOC görüntüleri ise en çok 500 px'tir ve 640 px'te 1.28 kat büyütülür (VOC testte küçük nesne oranı %4.7'den %1.85'e iner). Eğitim çözünürlüğü tek değişken kuralı gereği VOC'la aynı (640 px) tutuldu. 832 px test girişinin KITTI'de kazandırıp VOC'ta kaybettirmesinin ve çok ölçekli eğitimin (H01) KITTI'de kabul alıp VOC'ta almamasının en basit hipotezi bu farktır: KITTI'de küçük nesne payı yüksek olduğundan daha yüksek etkin çözünürlük yarar sağlayabilir, VOC'ta nesneler 640 px'te zaten büyütülmüştür. Hipotez sınanmadı.

Taban model makullüğü.

KITTI'de bu bölme ve değerlendirme kuralıyla yayımlanmış bir çıpa bulunmadığından VOC'taki makullük kapısı uygulanmadı. Yerine üç denetim yapıldı. Birincisi eğitim hattı tanısıdır: taban model `last.pt` ağırlıkları eğitim görüntülerinde yüksek, doğrulamada düşük mAP50-95 verir (sayılar: Ek C.4). İkincisi mutlak değerlerdir (`DontCare` kurallı, üç tohum ortalaması; puan): test mAP50-95'i YOLO11s'te 19.30 (`best.pt`) ve 19.66 (`last.pt`), YOLO26n'de 18.85 ve 17.35; `best.pt` doğrulama mAP50-95'i YOLO11s'te 19.26 ± 2.10, YOLO26n'de 18.51 ± 1.49; test car AP50-95'i (`best.pt`) YOLO11s'te 57.66, YOLO26n'de 58.10'dur. Bu değerler yalnız Δ'ların ölçeğini verir; kıyas çıpası değildir, VOC değerleriyle ya da modeller arasında kıyaslanmaz. Üçüncüsü, yalnız büyüklük mertebesi için bir dış kaynak değeridir (Ek D.6); çözünürlük, bölme ve değerlendirme farklı olduğundan bizim değerlerimizle karşılaştırılamaz.

C.2 KITTI ikincil sonuçları ve koşum başına en iyi epoch

Bu alt bölüm, KITTI kural belgesinde tanımlı ikincil raporları verir. Hepsi betimseldir; Holm düzeltmesi ve anlamlılık iddiası yoktur.

Tablo C1'de `DontCare`'siz test Δ'sı, 14 kartın hiçbirinde birincil (`DontCare` kurallı) Δ'dan 0.24 puandan fazla ayrılmaz; birincil sonuç yok-say kuralına duyarlı değildir. YOLO11s H01'in kazancı standart üç sınıfta (car, pedestrian, cyclist) $+0.48 \pm 1.72$'dir (tohum Δ'ları +1.57, −1.50, +1.38); person_sitting hariç yedi sınıflık alt kümede $+1.72 \pm 0.29$'dur (üç tohumda pozitif). Fark, standart üç sınıfa van, truck, tram ve misc eklenince ortaya çıkar; bu sınıfların test nesne sayıları car'dan (4 457) çok azdır (van 464, misc 184, tram 126, truck 119; person_sitting 56). Bu sayılarla sınıf başına AP gürültülüdür ve kazancın tek tek sınıflara dağılımı bu veriyle ayrıştırılamaz. Ters yönde bir örnek: YOLO26n'de H03'ün üç sınıflık farkı $+2.81 \pm 0.65$ (üç tohumda pozitif), H08'inki $+2.68 \pm 1.32$'dir; bu iki kartın birincil Δ'ları bunun çok altındadır (Tablo 5). Doğrulama eğri sütunu, eğitim sırasındaki doğrulama mAP50-95'inin 11.–90.

Tablo C1 KITTI önceden belirlenmiş ikincil betimsel kıyaslar: kart − taban model Δ ortalama ± s.d. [puan], $n = 3$ tohum-eşli; Holm yok, renk yok.

	Test Δ			Val Δ
Kart	DontCare'siz	3 sınıf	7 sınıf	ep11–90 eğri
YOLO26n				
H01 multi-scale	+0.05 ± 2.19	+1.22 ± 1.18	+0.08 ± 2.52	−0.31 ± 0.03
H02 Inner-CIoU	−1.01 ± 1.98	+1.04 ± 1.17	−1.02 ± 2.29	+0.51 ± 0.52
H03 kutu copy-paste	+0.88 ± 0.68	+2.81 ± 0.65	+1.07 ± 0.87	+0.62 ± 1.02
H04 mosaic scale	−1.33 ± 2.19	−0.97 ± 1.38	−1.53 ± 2.46	−0.54 ± 0.48
H05 Varifocal	+0.47 ± 1.48	+1.28 ± 1.16	+0.78 ± 1.73	+1.29 ± 0.20
H06 kutu kazancı	−0.24 ± 0.72	+0.56 ± 1.68	−0.26 ± 0.86	+0.33 ± 0.71
H08 yüksek doz	+0.67 ± 0.68	+2.68 ± 1.32	+0.73 ± 0.89	+1.01 ± 0.83
YOLO11s				
H01 multi-scale	+1.48 ± 0.39	+0.48 ± 1.72	+1.72 ± 0.29	+0.59 ± 0.57
H02 Inner-CIoU	+1.13 ± 0.48	+0.06 ± 1.75	+1.38 ± 0.66	−0.27 ± 0.55
H03 kutu copy-paste	+1.17 ± 1.00	+0.22 ± 2.73	+1.50 ± 1.17	+1.01 ± 0.55
H04 mosaic scale	+1.00 ± 0.83	−0.66 ± 1.86	+0.86 ± 1.30	−0.36 ± 1.36
H05 Varifocal	+2.35 ± 0.96	+1.41 ± 2.06	+2.73 ± 1.60	+0.53 ± 0.37
H06 kutu kazancı	+0.45 ± 0.65	+0.13 ± 1.31	+0.57 ± 0.79	−0.38 ± 0.29
H08 yüksek doz	+1.63 ± 2.89	+1.30 ± 4.20	+1.66 ± 4.04	+1.00 ± 0.39

Test (`best.pt`): DontCare'siz mAP50-95; DontCare kurallı alt kümeler: car, pedestrian, cyclist (3 sınıf) ve person_sitting hariç 7 sınıf. Val: eğitim eğrisinin (Ultralytics, DontCare'siz) 11.–90. epoch ortalaması. Test nesne sayısı: person_sitting 56, tram 126, truck 119.

epoch ortalamasının taban modelden farkıdır; H05 için YOLO26n'de $+1.29 \pm 0.20$, YOLO11s'te $+0.53 \pm 0.37$'dir (Ek C.3).

Tablo C2 her koşumun en iyi epoch'unu ve eğitim-içi en iyi eksi son epoch doğrulama farkını verir. YOLO11s'te 24 koşumun 11'inde en iyi epoch 1'dir (tohum 0'da 2, tohum 1'de 3, tohum 2'de 6); YOLO26n'de hiçbirinde değildir. Fark 48 koşumun tümünde pozitiftir (`best.pt` doğrulama üzerinde seçildiğinden beklenir) ve Ultralytics'in eğitim-içi (`DontCare`'siz) değerlendiricisiyle ölçülür: 24 koşum ortalaması YOLO26n'de +4.03, YOLO11s'te +4.58, yalnız taban model için +4.37 ve +4.39 puandır. Bu sayılar, Ek C.4'teki +3.23 ve +3.84'ten (bu çalışmanın COCO-tarzı yeniden değerlendirmesi) farklı bir ölçümdür.

Tablo C3 kart başına ikincil test ölçütlerini, kart başına doğrulama Δ'sını ve eğitim-içi ile yeniden değerlendirme farkını verir; B satırı mutlak değerdir. YOLO11s'te mAP50 (+0.80 ile +2.14), AP_S (+1.28 ile +5.69), AP_M (+0.58 ile +1.60) ve AP_L'nin (+1.28 ile +4.31) dördünde de yedi kartın yedisi pozitiftir; doğrulama Δ'sı da yedi kartta pozitiftir. Bu, tek bir kartın özgül etkisinden çok, tüm kartları aynı taban modele karşı kaydıran ortak bir farkla uyumludur (Ek C.4). YOLO26n'de işaretler karışıktır: pozitif kart sayısı mAP50'de 4/7, AP_S'de 3/7, AP_M'de 4/7, AP_L'de 4/7'dir. Son sütun, eğitim-içi en iyi doğrulama değeri ile aynı `best.pt` ağırlığının COCO-tarzı `DontCare`'siz yeniden değerlendirmesi arasındaki farktır: 24 koşum ortalaması YOLO26n'de +0.37, YOLO11s'te +0.40, 48 koşum aralığı −1.03 ile +1.80'dir (37/48

Tablo C2 KITTI: koşum başına en iyi epoch (`best.pt`) ve val best−last farkı [puan]; 48 koşum, tohum s0–s2. Eğik: epoch 1.

	s0		s1		s2	
Kol	Epoch	Fark	Epoch	Fark	Epoch	Fark
YOLO26n						
B taban model	16	+4.3	11	+5.1	28	+3.7
H01 multi-scale	24	+3.8	9	+4.6	20	+5.3
H02 Inner-CIoU	29	+3.8	11	+4.0	38	+3.1
H03 kutu copy-paste	10	+4.7	24	+4.4	37	+2.6
H04 mosaic scale	16	+5.5	11	+4.0	12	+5.4
H05 Varifocal	46	+2.9	39	+4.2	33	+2.8
H06 kutu kazancı	51	+2.9	11	+4.8	28	+3.4
H08 yüksek doz	39	+3.4	12	+4.6	48	+3.3
YOLO11s						
B taban model	9	+4.4	32	+3.1	*1*	+5.7
H01 multi-scale	15	+4.6	48	+3.9	*1*	+5.5
H02 Inner-CIoU	29	+4.6	38	+4.6	*1*	+6.6
H03 kutu copy-paste	*1*	+4.8	12	+2.7	*1*	+5.2
H04 mosaic scale	39	+5.1	*1*	+7.4	*1*	+6.1
H05 Varifocal	47	+2.7	54	+1.9	17	+3.2
H06 kutu kazancı	13	+4.9	*1*	+3.6	*1*	+6.5
H08 yüksek doz	*1*	+2.9	*1*	+6.3	24	+3.9

Val farkı: eğitim-içi en iyi − son epoch mAP50-95 (Ultralytics, DontCare'siz). En iyi epoch 1 olan koşum: YOLO26n 0/24, YOLO11s 11/24.

koşumda pozitif). `best.pt` Ultralytics uygunluğuyla seçildiğinden, birincil uç noktanın değerlendiricisinden farklı bir ölçüte dayanır. AP_S COCO'nun küçük nesne sınıfıdır ve YOLO26n'de s.d.'ler bu sütunda 1.21 ile 3.08 arasındadır; tek tek kart farkları bu gürültüyle birlikte okunmalıdır.

Tablo C4 sınıf başı AP50-95 Δ'sını verir. Sınıfların test nesne sayıları car'dan çok azdır (sayılar yukarıda ve tablo dipnotunda); bu yüzden az örnekli sınıflarda s.d.'ler farkların kendisinden büyük kalabilir (örnek: YOLO11s H01'de truck $+0.1 \pm 3.0$) ve kazancın sınıflara dağılımı bu veriyle ayrıştırılamaz.

C.3 H05'in KITTI'deki eğitim eğrisi

Aynı müdahale KITTI'de VOC'taki kaybı vermedi (Bölüm 7.2). Ölçülen: H05, iki modelde de taban modelden daha geç tepe yapar (en iyi epoch YOLO11s'te 47/54/17, taban modelde 9/32/1; YOLO26n'de 46/39/33, taban modelde 16/11/28; 6/6 tohumda daha geç, ancak YOLO11s tohum 2'de taban modelin en iyi epoch'u 1 olduğundan bu halka zayıftır). Geç tepe en tutarlı biçimde H05'te görülür: diğer altı kartta taban modelden daha geç tepe, iki modelin altı tohumundan en çok 4'ünde görülür (H02, H08). Doğrulama eğrisinin 11.–90. epoch ortalaması farkı YOLO26n'de kartlar arasında en büyüktür ($+1.29 \pm 0.20$, üç tohumda pozitif); YOLO11s'te ise H05'e özgü değildir

Tablo C3 KITTI ikincil ölçütler (`best.pt`): kart − taban model Δ ortalama ± s.d. [puan], $n = 3$ tohum-eşli; test DontCare kurallı. Betimsel, renk yok.

	Test Δ				Val [puan]	
Kart	mAP50	AP_S	AP_M	AP_L	Δ mAP50-95	İç−yeniden
YOLO26n						
B	33.59±0.89	7.92±2.61	15.94±1.05	32.71±0.94	–	+0.35±1.20
H01	+0.23±1.82	+0.05±1.21	−0.37±1.48	+2.32±3.38	−0.10±2.25	+0.21±1.01
H02	−1.31±2.54	+0.29±2.68	−0.51±2.18	−1.86±0.40	−0.29±0.80	+0.51±0.52
H03	+1.94±0.43	−0.10±1.47	+1.05±0.18	+1.81±3.11	+0.63±1.06	+0.19±0.46
H04	−1.90±2.14	−1.80±1.65	−0.83±2.08	−1.38±0.97	−0.22±1.89	+0.78±0.59
H05	+0.40±2.14	+0.13±1.82	+1.02±1.75	+0.57±2.08	+0.68±1.14	+0.44±0.53
H06	−0.38±1.10	−0.30±1.92	+0.18±1.31	−0.90±1.91	+0.09±0.65	+0.20±0.32
H08	+1.18±0.69	−1.24±3.08	+0.72±1.54	+0.96±1.53	+0.46±1.34	+0.29±0.52
YOLO11s						
B	35.39±0.65	7.20±0.91	18.14±0.80	31.92±0.86	–	+1.12±0.68
H01	+1.63±1.08	+2.58±1.61	+0.98±1.77	+2.74±2.76	+1.73±1.78	−0.01±0.33
H02	+1.87±2.46	+1.28±0.84	+0.95±0.84	+2.10±1.24	+1.15±1.05	+0.28±0.29
H03	+1.84±2.56	+2.50±2.35	+0.60±1.22	+1.28±1.94	+1.86±2.44	+0.65±0.54
H04	+2.14±0.26	+2.81±3.12	+0.81±1.34	+2.50±1.03	+1.82±0.43	+0.74±1.00
H05	+1.66±0.76	+4.37±2.90	+1.60±1.01	+2.30±1.57	+0.33±2.09	+0.47±0.33
H06	+0.80±1.62	+5.69±1.31	+0.62±0.40	+2.10±1.00	+1.24±0.56	+0.03±0.38
H08	+2.04±1.65	+1.99±1.28	+0.58±0.85	+4.31±1.98	+2.21±3.24	−0.06±0.61

Kartlar Tablo 5'dedir. Val Δ: DontCare kurallı mAP50-95. İç−yeniden: eğitim-içi en iyi val (Ultralytics) − aynı ağırlığın COCO-tarzı DontCare'siz yeniden değerlendirmesi. B satırı (taban model) mutlak değerdir; $AP_S/AP_M/AP_L$ COCO alan sınıflarıdır.

(+0.53 ± 0.37; H03 +1.01, H08 +1.00; Tablo C1). Mekanizma her koşumda devredeydi. Kalan hipotez ve sınırı için bkz. Bölüm 7.2 (S2'nin yanıtı).

C.4 Kontrol noktası seçimi: `best.pt` analizi

Bu alt bölüm, ana metinde özetlenen `best.pt` seçimine duyarlılığın ayrıntısıdır (Bölüm 7.2); analiz keşifseldir. Belirti, YOLO11s'te yedi kartın yedisinde pozitif çıkan `best.pt` Δ'sıdır (VOC'ta aşağı yönlü olan H02 ve H05 dahil; Şekil C1b). Dört aday açıklama sınandı (sonuç: aşağıda): erken tepe, 10 sahne grubundan oluşan doğrulama kümesinin gürültüsü, taban model tohum 2'nin aykırılığı ve `best.pt`'nin `DontCare`'siz doğrulama uygunluğuyla seçilmesi (birincil uç nokta `DontCare` kurallıdır).

Kart başına `best.pt` ve `last.pt`.

Şekil C1 kart başına `best.pt` ve `last.pt` Δ'sını yan yana çizer. YOLO11s'te (b) `best.pt` Δ'sı, VOC'ta aşağı yönlü olan H02 ve H05 dahil, yedi kartın yedisinde pozitiftir; `last.pt` Δ'ları ise sıfır çevresinde dağılır. YOLO26n'de (a) örüntü aynadır: `best.pt`'de üç kart negatiftir, `last.pt`'de yedi kartın yedisi taban modelin üstündedir. Sağlamlık etiketi 14 kartın 7'sinde "`best.pt` seçimine duyarlı" çıktı (Tablo 5);

Tablo C4 KITTI test: sınıf başı AP50-95 (DontCare kurallı, `best.pt`) kart − taban model Δ ortalama ± s.d. [puan], $n = 3$ tohum-eşli. Betimsel, renk yok.

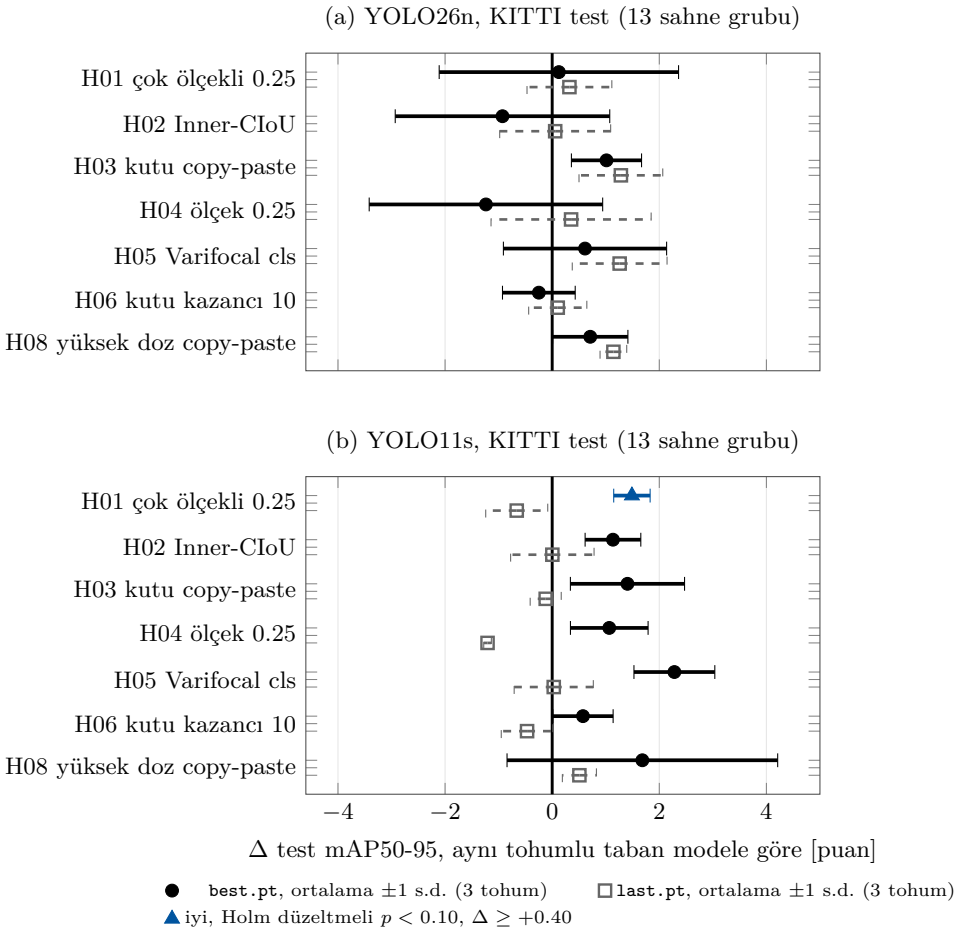
Kart	car	van	truck	ped.	sit.	cyc.	tram	misc
YOLO26n								
B	58.1	12.4	13.7	24.5	1.1	7.2	33.3	0.6
H01	−0.6±2.0	+0.2±1.9	−1.6±4.0	+1.8±2.0	+0.5±0.5	+2.5±2.6	−1.5±11.0	−0.1±0.4
H02	+0.3±1.2	−1.6±1.9	−3.3±3.0	+0.4±2.4	−0.3±0.8	+2.4±0.8	−5.5±12.3	+0.1±0.3
H03	+0.5±1.3	+1.8±0.4	+1.4±2.9	+1.8±0.6	+0.6±0.9	+6.1±1.8	−4.3±5.2	+0.3±0.3
H04	−1.3±1.3	−0.5±2.5	−0.3±1.7	−2.4±2.0	+0.8±1.1	+0.7±1.3	−7.2±10.7	+0.2±0.5
H05	+1.3±0.4	+0.8±1.8	−3.2±4.3	+0.9±0.5	−0.5±0.1	+1.6±2.8	+3.1±5.9	+0.8±0.7
H06	−0.3±1.1	−0.6±1.3	−0.4±5.6	−0.1±1.2	−0.2±0.8	+2.1±3.6	−2.6±8.6	+0.1±0.3
H08	+0.7±1.6	−0.8±2.0	+1.0±4.4	+2.2±1.4	+0.6±0.7	+5.2±1.1	−3.0±5.9	−0.1±0.4
YOLO11s								
B	57.7	12.8	13.5	27.0	3.4	15.7	22.9	1.4
H01	+2.2±0.9	+2.4±0.9	+0.1±3.0	+1.8±2.4	−0.1±0.7	−2.6±3.4	+8.2±3.0	−0.2±0.5
H02	+1.0±1.0	−0.4±3.0	+1.6±3.2	+1.1±0.7	−0.6±0.7	−1.9±4.9	+7.8±5.6	+0.5±0.6
H03	+1.7±1.6	+2.8±0.5	+3.9±3.4	+1.9±4.2	+0.7±5.1	−3.0±3.2	+2.9±4.1	+0.3±1.6
H04	−0.6±2.6	+3.1±5.2	+1.1±4.5	−0.3±1.0	+2.5±4.8	−1.1±4.6	+3.5±11.8	+0.3±1.1
H05	+4.3±1.8	+2.2±2.5	+4.1±2.5	+1.7±0.5	−0.8±5.4	−1.8±4.3	+8.3±6.8	+0.2±1.1
H06	+0.0±2.1	+1.5±3.9	+3.3±5.1	+2.6±2.9	+0.6±1.2	−2.1±4.9	−1.1±10.9	−0.1±1.0
H08	+2.1±4.0	+2.6±1.9	+1.4±4.3	+4.0±2.4	+1.9±8.5	−2.2±6.3	+2.7±21.6	+0.9±1.3

Kartlar Tablo 5'dedir; sit. = person_sitting. B satırı mutlak AP. Test nesne sayısı: car 4457, van 464, truck 119, ped. 574, sit. 56, cyc. 232, tram 126, misc 184.

YOLO11s'te H02 ve H05'in "seçimden bağımsız" etiketi, `last.pt` Δ'ları ≈0 olduğundan işaret kuralının sınır durumudur. Kartların ortak kayması (yedi kartın ortalama test mAP50-95'i eksi taban model ortalaması) YOLO11s'te `best.pt`'de +1.38, `last.pt`'de −0.27 puandır (YOLO26n'de +0.01 ve +0.65), yani taban modelin kontrol noktasına bağlıdır. Yedi kart tek bir taban modele karşı ölçüldüğünden 7/7 yedi bağımsız kanıt değildir; kümeli GA'nın YOLO11s'te beş kartta sıfırı dışlaması da kart etkisinden çok bu ortak kaymayla uyumludur. Hipotez kalan açıklama: 10 sahne gruplu küçük doğrulama kümesinde `best.pt` seçimi (YOLO11s'te sık sık epoch-1 ağırlığı) bu kümeye özgü, testte kısmen taşınmayan bir tepeyi yakalar (seçilenin laneti ve sahne grubu gürültüsü). Diğer açıklamalar ve eğitim hattı tanısı Ek C.4'tedir; açıklamayı ayıracak deney (ara epoch'larda sabit epoch değerlendirmesi ya da daha çok tohum) koşulmadı.

Epoch-1 ağırlıkları.

YOLO11s'in 24 koşumunun 11'inde en iyi epoch 1'dir, 16'sında 20'nin altındadır ve medyan 10.5'tir (Tablo C2); YOLO26n'de en iyi epoch 1 olan koşum yoktur (0/24), 10'u 20'nin altındadır ve medyan 24'tür. YOLO11s tohum 2'de sekiz kolun altısında (taban model, H01, H02, H03, H04, H06) `best.pt` epoch-1 ağırlığıdır. Kart–taban model kıyaslarından beşi iki epoch-1 ağırlığı arasındadır ve test Δ ortalaması +1.235'tir (aralık +0.634 ile +1.593); beş kıyas aynı taban model ağırlığına dayandığından bağımsız



Şekil C1 KITTI test: kart başına taban modele göre Δ mAP50-95 [puan], `best.pt` ve `last.pt` için üç tohum ortalaması ±1 s.d.; (a) YOLO26n, (b) YOLO11s. Mavi üçgen Holm-5 kabulüdür.

değildir. Taban model tohum 2'nin test mAP50-95'i `best.pt`'de 18.22, `last.pt`'de 19.83'tür.

Eğitim hattı.

1000 eğitim görüntüsünde mAP50-95 şöyledir: YOLO26n taban model tohum 0'da `best.pt` 56.06, `last.pt` 78.42 (aynı `best.pt`'nin doğrulama değeri 17.89); YOLO11s taban model tohum 0–2'de `last.pt` 85.13, 85.00 ve 85.25 (aynı ağırlıkların doğrulama değeri 14.8–15.9). Epoch-1 `best.pt` eğitim sahnelerini henüz öğrenmemiştir: YOLO11s tohum 2'de 36.74 (tohum 0 ve 1'de, en iyi epoch 9 ve 32, 49.84 ve 69.93). Düşük doğrulama ve test düzeyi hat hatasıyla değil, genelleme açığıyla uyumludur. Olası nedenler 36 eğitim sahne grubuna aşırı uyum ve VOC'taki davranışı korumak için sabitlenen optimizatör ile öğrenme hızının (MuSGD, 0.01) bu veriye uymamasıdır. Üçüncü bir olasılık, tam ince ayarın önceden eğitilmiş özellikleri sahne-ayrık doğrulama

ve testte bozmasıdır; bu etki büyük dağılım kayması altında gösterilmiştir [5], ancak KITTI bölmelerindeki kaymanın büyüklüğü ölçülmedi. Üç olasılığın hiçbiri sınanmadı.

Seçim ölçütü uyumsuzluğu.

Uyumsuzluk hipotezi, geç epoch'ların `DontCare` bölgelerindeki tespitlerle cezalandırıldığını varsayar ve `DontCare` kuralıyla best−last farkının daralmasını öngörür. Aynı ağırlıklar bu çalışmanın COCO-tarzı değerlendiricisiyle doğrulamada `DontCare`'siz ve `DontCare` kurallı ölçüldüğünde ise fark 48 koşumun 48'inde genişler (ortalama YOLO26n'de +3.23'ten +3.62'ye, YOLO11s'te +3.84'ten +4.31'e); hipotez desteklenmez. Doğrulamada `best.pt`'nin `last.pt`'den 48/48 koşumda iyi olması yapısaldır (`best.pt` doğrulama üzerinde seçilir) ve ayırt edici değildir. Ultralytics'in eğitim-içi (`DontCare`'siz) değerlendiricisi ayrı bir ölçümdür; `best.pt` birincil uç noktanın değerlendiricisiyle değil, onun uygunluğuyla seçilir (sayılar: Tablo C2). Testte taban modelin `best.pt` − `last.pt` farkı YOLO26n'de +1.50, YOLO11s'te −0.36'dır; `DontCare` kurallı doğrulama farkı ise +3.78 ve +3.43 puandır. YOLO11s'te doğrulama tepesinin testte karşılığı görülmez, YOLO26n'de kısmen taşınır.

Ortak kayma.

Kartların taban modele göre ortak kayması (yedi kartın ortalama test mAP50-95'i eksi taban model ortalaması) YOLO11s'te `best.pt`'de +1.38, `last.pt`'de −0.27 puandır (fark 1.65). YOLO26n'de örüntü aynadır: kayma `best.pt`'de +0.01, `last.pt`'de +0.65'tir (Şekil C1a). Ortak kayma, taban modelin hangi kontrol noktasıyla temsil edildiğine bağlıdır; yedi kart tek bir taban modele karşı ölçüldüğünden 7/7 yedi bağımsız kanıt değildir. Tohum 2'deki aykırılık örüntüyü tek başına açıklamaz: YOLO11s'te tohum 0 ve 1'de de yedi kartın yedisi pozitiftir (tohum başına ortak kayma +1.36 ve +0.78; tohum 2'de +1.99). İşaret kuralı YOLO11s'teki H02 ve H05'e "seçimden bağımsız" etiketi verir; ancak bu iki kartın `last.pt` Δ'ları sıfırdır (+0.00, +0.03) ve `best.pt`'deki büyüklük (+1.14, +2.28) seçime bağlıdır. Etiket bu iki kartta işaret kuralının sınır durumudur.

Sonuç.

H01 kabulü önceden yazılmış kuralla raporlanır, ama "`best.pt` seçimine duyarlı" etiketiyle ve kazancın çoğunun tek bir test sahne grubundan geldiği notuyla; sağlam bir iyileşme iddiası yapılmaz. Ölçülen: YOLO11s'te `best.pt` ve `last.pt` Δ'ları sistematik biçimde ayrışır, YOLO26n'de ayrışma ters yöndedir. Hipotez kalan: `best.pt` seçimi, küçük bir doğrulama kümesine (10 sahne grubu) özgü bir tepeyi yakalar ve bu tepe testte kısmen taşınmaz (seçim yanlılığı, "winner's curse", ve sahne grubu gürültüsü). Bunu ayıran deney (ara epoch'larda sabit epoch değerlendirmesi ya da daha çok tohum) koşulmadı.

C.5 KITTI sağlamlık analizi (kilit sonrası, keşifsel)

Bu analizler KITTI testi açıldıktan sonra yapıldı; yeni test açılışı, yeni çıkarım ya da eğitim yoktur, mevcut `best.pt` ve `last.pt` test tahminleri yeniden okundu ve tam örneklemde kayıtlı Δ'lar yeniden üretildi. Önceden yazılmış kurallarda yer almazlar ve Holm düzeltmesi uygulanmadı.

Tablo C5'teki hiyerarşik bootstrap her çoğaltmada önce üç tohumu, sonra 13 test sahne grubunu yerine koyarak çeker; grup çekimi tüm kartlar ve tohumlar için ortaktır (eşli). Tohum çekimi $n = 3$ üzerinden yapıldığından aralıklar hâlâ iyimser olabilir. Aralık 14 kartın 13'ünde sıfırı kapsar (YOLO11s H01 sayıları: Bölüm 7.2). Sekiz sınıflı Δ'da sıfırı dışlayan tek kart (mavi) YOLO11s H05'tir ([+0.20, +4.10]). H02 ve H05 yönlü replikasyon kartlarıdır (beklenen $\Delta < 0$) ve H05'in `last.pt` Δ'sı $\approx$0'dır; bu yüzden mavi hücre bir iyileşme iddiası değildir. Tram'sız ve 6 sınıf sütunlarında aralık gösterilmediğinden renk verilmez; bu alt kümelerin aralığı tram'sız Δ'da YOLO11s H05 için [+0.11, +3.32], H08 için [+0.07, +3.34]'tür. Pozitif grup sütunu görüntü ağırlıksızdır ve küçük gruplarda (5–6 görüntü) tek-grup Δ'ları kararsızdır.

YOLO11s H01 kabulünün diğer duyarlılıkları şunlardır. Kümeli bootstrap'ın tek yönlü p'si 0.0535'tir (önceden yazılmış değil, duyarlılık). Kabul, t testinin normallik varsayımına dayanır: üç tohumla işaret-çevirme testinin ulaşabileceği en küçük tek yönlü p 0.125'tir. Kural belgesi modeller arası havuzlamayı öngörmez; duyarlılık olarak iki modelin 10 iyileşme sınaması birlikte Holm-10 ile düzeltildiğinde $p = 0.0848$, 14 testin tümü tek ailede toplandığında $p = 0.119$ çıkar. Bu değerler önceden yazılmış kararı değiştirmez. drive_0056 dışarıda bırakıldığında H01'in Δ'sı +1.49'dan +0.45'e iner ($\approx$%70 düşüş); mAP gruplar üzerinde toplamsal olmadığından bu bir dışarıda bırakma farkıdır. Kazanç standart üç sınıfta (car, pedestrian, cyclist) görülmez, az örnekli sınıflardan gelir (Tablo C1).

Kümeli bootstrap GA, sabit ağırlıklarda yalnız test sahne gruplarının örnekleme belirsizliğini ölçer ve tohum varyansını içermez. Kabul alamayan iyileşme kartlarında üst sınırı en çok +2.92 (YOLO26n) ve +2.76'dır (YOLO11s). YOLO11s'te yedi kartın beşinde (H03, H04, H05, H06, H08) sıfırı dışlar, kabul alan H01'de ise keser; YOLO26n'de hiçbir kartta sıfırı dışlamaz. Bu örüntü kart-özgü bir etkiden çok, tüm kartları aynı taban modele karşı kaydıran ortak bir farka işaret eder (Ek C.4) ve kart etkisinin kanıtı sayılmaz.

Doğrulama (987 görüntü, 10 sahne grubu; ikincil uç nokta) testle aynı kartı seçmedi. YOLO26n'de doğrulamada da kabul yoktur. YOLO11s'te doğrulamada kabul ölçütünü yalnız H04 sağladı ($+1.82 \pm 0.43$, $p_{\text{Holm}} = 0.046$; karar değildir); H01 doğrulamada $+1.73 \pm 1.78$ ile kabul almadı ($p_{\text{Holm}} = 0.350$). Testte tablo tersine döner: H01 ölçütü sağlar, H04 ($+1.07 \pm 0.72$, $p_{\text{Holm}} = 0.252$) sağlamaz. İki kümenin farklı kart seçmesi, YOLO11s'teki tek kabulün hangi kartta çıktığının sahne grubu örneklemesine duyarlı olmasıyla uyumludur.

C.6 Eğitimsiz çıkarım (H07) ayrıntıları

H07 taban model `best.pt` ağırlıklarıyla ve doğrulamada yapıldı; teste model başına doğrulamada en yüksek ortalamalı tek satır girdi. YOLO11s'te bu ağırlıkların tohum 2'sinin `best.pt`'si epoch-1 ağırlığıdır (Ek C.4). YOLO26n'de seçilen U832 satırı doğrulamada +1.50, testte $+1.54 \pm 0.58$ puan verdi; gecikme batch 1'de 7.74 ms'den 7.80 ms'ye çıktı (oran 1.008), yani önceden yazılmış $\times 1.10$ bütçesinin içindedir. Piksel sayısı 1.69 kat artarken gecikmenin yalnız %0.8 artması, ölçümün görüntü başına Python ve ön-işleme ek yüküyle domine edildiğini düşündürür; VOC'ta aynı satırın gecikme oranı 1.14 idi. YOLO11s'te seçilen W2 satırı (T2 dallarının WBF füzyonu) doğrulamada +1.61, testte $+2.02 \pm 0.95$ verdi; gecikme 6.82 ms'den 26.70 ms'ye ($\times 3.91$) çıktı ve

önceden yazılmış $\times 1.10$ bütçesinin dışındadır. İki modelin gecikme motoru farklıdır (YOLO11s: VOC motoru; YOLO26n: görüntü başına `predict`); R0'da nano 7.74 ms, small 6.82 ms çıkar, bu yüzden mutlak ms modeller arasında kıyaslanmaz, yalnız model-içi oran okunur. Bu Δ'lar aynı ağırlıkla ölçüldüğünden kartlar ile taban model arasındaki `best.pt` seçim farkını içermez; ancak tek satırlı, üç tohumlu ve keşifseldir, GA ve Holm verilmedi. VOC doğrulamasında 832 px girişi mAP50-95'i -5.19 düşürmüştü (Bölüm 5.2); KITTI'de aynı satırın işareti pozitiftir. Bu zıtlık için sınanmamış hipotez, yukarıdaki çözünürlük farkıdır (Ek C.1).

Gecikme ölçüm hatası ve düzeltmesi.

KITTI H07 betiğinin ilk koşumu, seçilen satırın gecikme ölçümünde CUDA bellek yetersizliğiyle düştü; hiçbir gecikme değeri yazılmadı. Görüntü yolları `predict`'e tek kaynak listesi olarak verilmişti ve Ultralytics listeyi tek batch'te işler; kural belgesindeki batch 1 sağlanmıyordu. Hata, hiçbir gecikme değeri üretilmeden ve KITTI testi açılmadan düzeltildi: YOLO11s için VOC H07 ölçüm motoru birebir, YOLO26n için görüntü başına `predict` ve GPU eşzamanlaması kullanıldı. 50 ısınma, 300 ölçüm ve FP16 değişmedi; doğruluk satırlarının tanımı ve seçim kuralı da değişmedi. Bildirilen KITTI gecikmeleri düzeltilmiş ölçümdendir; VOC gecikmeleri etkilenmedi.

Tablo C5 KITTI test sağlamlık (kilit sonrası, keşifsel): kart − taban model Δ [puan]; tohum ve 13 sahne grubunda hiyerarşik bootstrap ($B = 2000$). Mavi+kalın: GA sıfırı dışlar.

Kart	Δ	Hiyerarşik GA95	$P(\Delta \leq 0)$	Tram'sız Δ	6 sınıf Δ	Poz. grup
YOLO26n						
H01 multi-scale	+0.12	[−2.26, +2.51]	0.401	+0.36	+0.11	5/13
H02 Inner-CIoU	−0.93	[−2.82, +0.85]	0.778	−0.28	−1.21	5/13
H03 kutu copy-paste	+1.01	[−0.81, +3.36]	0.093	+1.78	+1.20	7/13
H04 mosaic scale	−1.24	[−3.05, +1.65]	0.758	−0.38	−1.81	9/13
H05 Varifocal	+0.61	[−1.53, +2.32]	0.278	+0.25	+0.77	7/13
H06 kutu kazancı	−0.25	[−2.06, +1.54]	0.600	+0.09	−0.31	5/13
H08 yüksek doz	+0.71	[−0.93, +2.73]	0.147	+1.24	+0.87	7/13
YOLO11s						
H01 multi-scale	+1.49	[−0.67, +2.61]	0.077	+0.53	+2.03	9/13
H02 Inner-CIoU	+1.14	[−0.76, +2.37]	0.120	+0.19	+1.53	10/13
H03 kutu copy-paste	+1.41	[−0.36, +3.50]	0.050	+1.20	+1.70	11/13
H04 mosaic scale	+1.07	[−1.00, +3.01]	0.116	+0.72	+0.96	11/13
H05 Varifocal	**+2.28**	**[+0.20, +4.10]**	**0.018**	+1.42	+3.15	9/13
H06 kutu kazancı	+0.57	[−0.81, +2.68]	0.150	+0.82	+0.68	10/13
H08 yüksek doz	+1.68	[−0.45, +4.62]	0.084	+1.54	+1.78	11/13

$P(\Delta \leq 0)$: bootstrap'ta $\Delta \leq 0$ oranı. Tram'sız: 7 sınıf; 6 sınıf: person_sitting ve misc hariç; bu iki sütunda renk yoktur (GA gösterilmez). Poz. grup: tohum-ortalama $\Delta > 0$ olan sahne grubu. `best.pt`. H02, H05: yönlü kartlar (beklenen $\Delta < 0$).

Ek D Yöntem ayrıntıları ve hesap notları

Bu ek ana metnin Yöntem bölümünden çıkarılan ayrıntıları (hipotez kartı ve karar kuralları, kayıp terimlerinin açılımı, eğitim reçetesi, müdahale ayrıntıları) ve hesap notlarını verir; ön-eleme olasılıkları, gradyan normu oranı ve makullük çıpasının kaynakları makalenin Ek A'sındadır.

D.1 Hipotez kartı ve karar kuralı ayrıntıları

Kart ana metindeki alanlara ek olarak kabul sonrası ablasyonları da sabitler. Kart dosyası ilk koşumdan önce damgalanmalıdır (bu kuralın uygulamadaki kanıt gücü sınırlıdır; Bölüm 9). Birleşik kart ancak bileşenlerin her biri ayrı kabul almışsa yazılabilir. Beklenen aralıklar, izole bir VOC ablasyonu bulunamayan kartlarda dardır ve sıfır merkezlidir.

Ön-elemede yanlış eleme maliyeti yüksek olduğundan eşik tek-tohum oynaklığının altında tutulmuştur; sıfır etkide de geçiş olasılığı ihmal edilemediğinden geçiş ikinci doğrulama gerektirir. Sonradan üç tohuma tamamlanan elenen kartta SÜRDÜR ölçütünün karşılanmaması "isabet", karşılanması "kaçırılmış kazanç" diye betimlenir; isabet bir özgüllük ölçüsüdür ve bilgisiz bir kapıda da olası olduğundan bilgilendirici sayılmaz (makale Ek A.4). SÜRDÜR kuralında s_Δ, $\Delta_{k,s}$'lerin örneklem s.d.'sidir ve tek yönlü sınamanın alternatifi $H_1 : \bar{\Delta}_k > 0$'dır. İNCELE durumunda ek tohum yalnız K5 bütçesinden ve hem varyant hem taban model için eklenir. SÜRDÜR kuralı tur 2'de, H01–H03 sonuçları görüldükten sonra donmuştur; tur-2 kuralını geçen kart ($\bar{\Delta}_k \geq +0.40$) tur-1 kuralını da geçer, tersi doğru değildir.

D.2 Taban model kayıp terimlerinin açılımı

Taban modelin boynu üç ölçekte (adım 8, 16, 32) çıktı üreten yol toplama ağı (path aggregation network, PAN) tipindedir (üçüncü taraf bir derleme: [6]). TAL'da pozitiflerin sınıf hedefi $t_i = a_{ij} \max_{i'} u_{i'j} / \max_{i'} a_{i'j}$'dir. Ana metindeki Denklem (3)'te geçen CIoU [7] ve dağılım odaklı kayıp (distribution focal loss, DFL) [8] şöyledir:

$$\mathrm{CIoU} = \mathrm{IoU} - \frac{\rho^2(\hat{\mathbf{m}}, \mathbf{m})}{d^2} - \alpha_v v, \tag{D2}$$

$$\mathcal{L}_{\mathrm{dfl}} = \frac{1}{T} \sum_{i \in \mathcal{P}} w_i \, \frac{1}{4} \sum_{e=1}^{4} \Big[-\big((r_e + 1) - y_e\big) \log S_{e,r_e} - (y_e - r_e) \log S_{e,r_e+1} \Big]. \tag{D3}$$

Denklem (D2)'de $\hat{\mathbf{m}}$ ve $\mathbf{m}$ kutu merkezleri, ρ Öklid uzaklığı, d iki kutuyu kapsayan en küçük kutunun köşegeni, $v = \frac{4}{\pi^2}\big(\arctan \frac{w^{gt}}{h^{gt}} - \arctan \frac{\hat{w}}{\hat{h}}\big)^2$ en-boy terimi ve $\alpha_v = v/\big((1 - \mathrm{IoU}) + v\big)$'dir [7]. BCE, $\mathrm{BCE}(z, t) = -t \log \sigma(z) - (1 - t) \log(1 - \sigma(z))$'dir. Denklem (D3)'teki DFL [8] dört kenar uzaklığının her birini $R = 16$ ayrık bölme üzerinde bir softmax dağılımı S_e ile tahmin eder; y_e hedef uzaklık, $r_e = \lfloor y_e \rfloor$'dir.

D.3 Eğitim reçetesi ve veri artırma varsayılanları

Dönüşümler sırasıyla şunlardır. Olasılığı 1.0 olan mosaic dört görüntüyü $2s \times 2s$ boyutlu bir tuvalde birleştirir ($s = 640$) [9]. RandomPerspective ölçek çarpanını $a \sim U[1-\sigma_s, 1+\sigma_s]$ ile seçer ($\sigma_s = 0.5$), 0.1 oranında öteleme uygular (dönme, kayma ve perspektif sıfırdır) ve çıktıyı merkezdeki $s \times s$ pencereye kırpar. Ardından HSV kayması (hue-saturation-value; 0.015, 0.7, 0.4) ve olasılığı 0.5 olan yatay çevirme gelir. MixUp ve yerleşik copy-paste kapalıdır; mosaic son 10 epoch'ta (`close_mosaic=10`) kapanır. Yerleşik copy-paste maske gerektirdiğinden kutu etiketli VOC'ta etkisizdir [10]; H03 ve H08 kutu-tabanlı yeni bir uygulamaya dayanır.

D.4 Müdahale ayrıntıları

Ölçek ve kutu kaybı.

H01'in amacı aynı nesneyi farklı piksel yoğunluğunda göstererek ölçek değişmezliğini zorlamaktır. H04'te RandomPerspective ölçek aralığı $[0.5, 1.5]$'ten $[0.75, 1.25]$'e iner; genlik büyütülmez. H02'de her pozitif çapa için yardımcı kutu $b^{\text{in}} = (x_c, y_c, rw, rh)$'dir; DFL terimi, TAL ve kazançlar değişmez ve uygulama $r = 1$ özdeşlik birim testiyle doğrulanmıştır. H05'te etkin gradyan normu ölçülür (makale Ek A.5).

Kutu-tabanlı copy-paste.

Kopyala-yapıştır, küçük nesneleri aynı görüntüde çakışmasız çoğaltarak küçük nesne açığını kapatmayı dener [11]. Dönüşüm mosaic'ten sonra, RandomPerspective'ten önce çalışır; adaylar başka kutularla örtüşmeyen (IoA ≤ 0.1) nesnelerdir, $k \sim U\{1, 2, 3\}$ nesne seçilir ve 3 piksellik alfa harmanlamasıyla yapıştırılır (adımlar: Ek B.2). Maskesiz yama arka plan parçası da taşır; yama kenarını öğrenme riski AP_{75}'in izlenme nedenlerindendir. Dönüşüm son 10 epoch'ta kapalıdır. H03'te $p = 0.5$ ve $\tau_A = 48$ piksel, H08'de $p = 1.0$ ve $\tau_A = 96$ pikseldir. Yapıştırma eşikleri mosaic tuvalinde, $\text{AP}_S/\text{AP}_M/\text{AP}_L$ sınırları orijinal pikselde COCO tanımıyla ölçülür [12]. Havuzun genişlemesi yapıştırılanların boyut karışımını da değiştirdiğinden H08'de olasılık ve havuz ayrıştırılmamıştır. Doz $D = N_{\text{yapıştırılan}}/N_{\text{mosaic}}$ [nesne/mosaic] işçi süreçlerinin periyodik yazdığı sayaçlardan yaklaşık ölçülür. H08 kartında hedef doz $D \geq 0.80$ (beklenen aralık 0.8–1.2) olarak önceden yazılmıştır; koşum öncesi ölçülen D, [0.6, 1.5] kapısının dışındaysa koşum başlamaz. Hedefin altında kalan doz ikinci bir değişken doğurmamak için ayarlanmaz; gerçekleşen doz raporlanır.

Eğitimsiz çıkarım satırları (H07).

Referans hat R0, 0.001 güven eşiği, 0.7 NMS IoU eşiği, en çok 300 tespit, 640 piksel tek ölçek ve sınıf-bazlı klasik NMS kullanır. Her satır R0'dan yalnız bir bileşenle ayrılır ve satırlar birleştirilmez. *NMS eşiği (N)* IoU eşiğini {0.5, 0.6, 0.8}'den birine alır. *Soft-NMS (S)* örtüşen kutunun skorunu Gauss kuralıyla sınıf başına bozar ($\sigma \in \{0.3, 0.5\}$; tanım: Ek B.3) [3]. *Test çözünürlüğü (U)* girişi 704, 768 ya da 832 piksele çıkarır. *TTA (T)*: T1 Ultralytics varsayılanıdır [13, 14]; ölçekleri {1, 0.83, 0.67} olan üç dal çalışır, ortadaki dal yatay çevrilir ve dal çıktıları özgün koordinatta tek NMS'e verilir. T2'de ölçek listesi {1, 1.2, 1.4}'tür. Üç dal giriş pikseli toplamını $1 + 0.83^2 + 0.67^2 \approx 2.14$ katına çıkarır; gecikme buna dal birleştirme ve NMS eklenerek artar. *WBF (W)* T1 ya

da T2 dallarını ayrı ayrı NMS'ten geçirip füzyonla birleştirir (IoU eşiği 0.6, atlama eşiği 0.001, ortalama güven) [15]. Gecikme oranı aynı oturumda ölçülen R0'a göre hesaplanır; $\rho \leq 1.10$ eşiği, gerçek-zaman iddiasının taşınabileceği en büyük gecikme artışı olarak koşumdan önce belirlenmiştir. KAZANÇ satırları eğitim kartlarının ebeveyn zincirine girmez.

D.5 İstatistik ayrıntıları

Bölüm 3.3'teki "İstatistik" paragrafını ayrıntılandırır. Eğitim kartlarında tohum eşlemesi nominaldir, çünkü müdahale veri artırmanın rastgele sayı üreteci (RNG) tüketimini de değiştirir ve eşleştirme varyansı yalnız kısmen düşürür. Holm düzeltmesinin [16] on iki testlik K5 ailesi H03 ve TTA × altı metrikten oluşur (H03 mAP50-95 dahil, muhafazakâr sayım); Holm-7 yedi kartın üç tohumlu doğrulama farklarına uygulanır. Görüntü-düzeyi eşli bootstrap [17] aynı görüntü indekslerini varyanta ve taban modele uygular ($B = 1000$, yüzde 95 yüzdelik aralığı; üç tohumun Δ ortalaması). Bu aralık eğitim tohumu varyansını içermediğinden eğitim müdahaleleri için tohum düzeyinde aralık $\bar{\Delta}_k \pm t_{0.975,2}\, s_\Delta/\sqrt{n}$ ($t_{0.975,2} = 4.303$) de verilir. Düzeltmesiz $p < 0.05$ tablolarda renklendirilmez. Pratik marjlar (+0.30, +0.40 puan) istatistiksel ölçütten ayrı bir ölçüttür. K5'te taban modelin test mAP50-95 değeri her tohum için makullük denetimindeki değerle karşılaştırılır; uyuşmazlık düzeltilmeden raporlanır.

D.6 Dış kaynak değeri

KITTI taban modelinin büyüklük mertebesi için tek dış kaynak değeri, bir topluluk modeli kartıdır (YOLO11n, KITTI; https://huggingface.co/dronefreak/kitti-yolo11n, erişim 2026-10-22): doğrulama mAP50-95'i için 24.0, car AP50-95'i için 67.3 bildirir. Model 1280 px'te ve 3712/3769 bölmesinde eğitilmiş, `DontCare` işlemesi belirtilmemiş ve erken durdurma (43. epoch) ile raporlanan sayılar aynı doğrulama kümesine dayanır. Çözünürlük, bölme ve değerlendirme farklı olduğundan bizim değerlerimizle karşılaştırılamaz; hakemli bir kaynak değildir.

Kaynaklar

[1] Zhang, H., Xu, C., Zhang, S.: Inner-IoU: More Effective Intersection over Union Loss with Auxiliary Bounding Box. arXiv:2311.02877 (2023)

[2] Dwibedi, D., Misra, I., Hebert, M.: Cut, paste and learn: Surprisingly easy synthesis for instance detection. In: 2017 IEEE International Conference on Computer Vision (ICCV), pp. 1310–1319. IEEE, ??? (2017). https://doi.org/10.1109/ICCV.2017.146

[3] Bodla, N., Singh, B., Chellappa, R., Davis, L.S.: Soft-NMS – improving object detection with one line of code. In: 2017 IEEE International Conference on Computer Vision (ICCV), pp. 5562–5570. IEEE, ??? (2017). https://doi.org/10.1109/ICCV.2017.593

[4] Bolya, D., Foley, S., Hays, J., Hoffman, J.: TIDE: A general toolbox for identifying object detection errors. In: Computer Vision – ECCV 2020. Lecture Notes in Computer Science, pp. 558–573. Springer, ??? (2020). https://doi.org/10.1007/978-3-030-58580-8_33

[5] Kumar, A., Raghunathan, A., Jones, R., Ma, T., Liang, P.: Fine-tuning can distort pretrained features and underperform out-of-distribution. In: International Conference on Learning Representations (ICLR) (2022). https://arxiv.org/abs/2202.10054

[6] Khanam, R., Hussain, M.: YOLOv11: An Overview of the Key Architectural Enhancements (2024). https://doi.org/10.48550/arXiv.2410.17725

[7] Zheng, Z., Wang, P., Liu, W., Li, J., Ye, R., Ren, D.: Distance-IoU loss: Faster and better learning for bounding box regression. Proceedings of the AAAI Conference on Artificial Intelligence **34**(07), 12993–13000 (2020) https://doi.org/10.1609/aaai.v34i07.6999

[8] Li, X., Wang, W., Wu, L., Chen, S., Hu, X., Li, J., Tang, J., Yang, J.: Generalized focal loss: Learning qualified and distributed bounding boxes for dense object detection. In: Advances in Neural Information Processing Systems 33 (NeurIPS 2020), pp. 21002–21012. Curran Associates, Inc., ??? (2020). https://proceedings.neurips.cc/paper_files/paper/2020/file/f0bda020d2470f2e74990a07a607ebd9-Paper.pdf

[9] Bochkovskiy, A., Wang, C.-Y., Liao, H.-Y.M.: YOLOv4: Optimal Speed and Accuracy of Object Detection. arXiv:2004.10934 (2020)

[10] Ultralytics: Data Augmentation using Ultralytics YOLO. https://docs.ultralytics.com/guides/yolo-data-augmentation/. Çevrimiçi belge. Erişim: 2026-10-01 (2026)

[11] Kisantal, M., Wojna, Z., Murawski, J., Naruniec, J., Cho, K.: Augmentation for Small Object Detection. arXiv:1902.07296 (2019)

[12] Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., Zitnick, C.L.: Microsoft COCO: Common objects in context. In: Computer Vision – ECCV 2014. Lecture Notes in Computer Science, pp. 740–755. Springer, ??? (2014). https://doi.org/10.1007/978-3-319-10602-1_48

[13] Ultralytics: Test-Time Augmentation (TTA) — YOLOv5 dokümantasyonu. https://docs.ultralytics.com/yolov5/tutorials/test_time_augmentation/. Çevrimiçi belge. Erişim: 2026-09-29 (2026)

[14] Ultralytics: ultralytics v8.4.165 (sürüm etiketi). https://github.com/ultralytics/ultralytics/releases/tag/v8.4.165. Yazılım, sürüm 8.4.165, commit 004db34b12f65fa5a160de2b1090f6943106bd35. Erişim: 2026-09-29 (2026)

[15] Solovyev, R., Wang, W., Gabruseva, T.: Weighted boxes fusion: Ensembling boxes

from different object detection models. Image and Vision Computing **107**, 104117 (2021) https://doi.org/10.1016/j.imavis.2021.104117

[16] Holm, S.: A simple sequentially rejective multiple test procedure. Scandinavian Journal of Statistics **6**(2), 65–70 (1979)

[17] Efron, B.: Bootstrap methods: Another look at the jackknife. The Annals of Statistics **7**(1), 1–26 (1979) https://doi.org/10.1214/aos/1176344552